Анализ каталога Netflix

Проект по дисциплине «Введение в анализ данных»

Цель проекта

В этом проекте я решил посмотреть, что можно узнать из открытого датасета Netflix. Основная цель работы - потренироваться работать с реальными данными: загрузить таблицу, посмотреть её содержимое, найти простые зависимости и построить несколько графиков. По сути, это небольшой разведочный анализ данных (EDA).

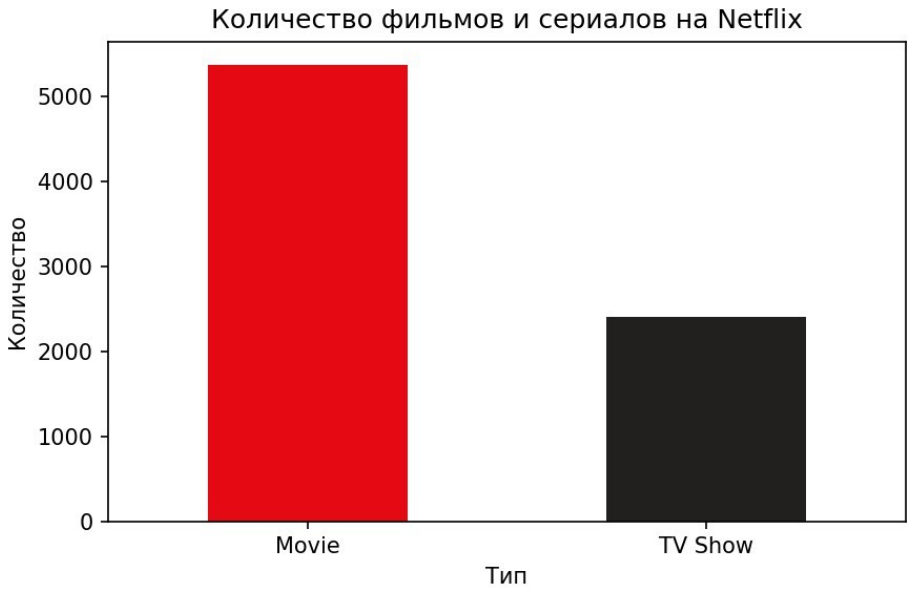
Источник данных

Для работы я использовал датасет с фильмами и сериалами Netflix из репозитория TidyTuesday на GitHub. Изначально эти данные были собраны сервисом Flixable, а позже опубликованы на Kaggle под названием «Netflix Movies and TV Shows». В наборе 7787 записей и 12 основных признаков: тип контента, страна, год выпуска, длительность, возрастной рейтинг, жанры и другие данные.

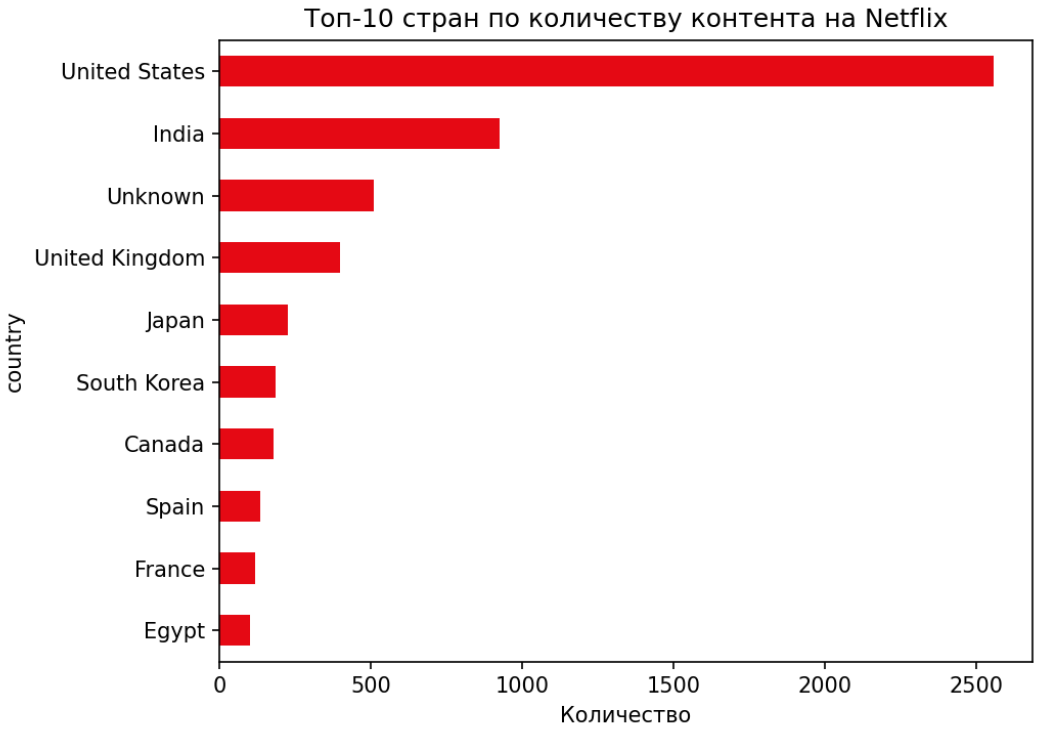
Ход работы

Сначала я загрузил таблицу и посмотрел её размер, названия столбцов и общую информацию о данных. Также было видно, что в некоторых столбцах есть пропуски, особенно в информации о стране, режиссёрах и актёрском составе.

После этого я сравнил количество фильмов и сериалов и вывел результат на графике.



Для анализа по странам я сначала заменил пропущенные значения в столбце country на «Unknown». Это позволило учитывать такие записи при подсчёте и не терять их из выборки.



Дальше я решил посмотреть, как меняется количество контента в зависимости от года выпуска. Для этого данные были сгруппированы по годам, после чего я взял последние 15 лет и построил график.



Ещё отдельно посмотрел на длительность фильмов. В исходной таблице она записана как текст, например «90 min», поэтому сначала нужно было убрать слово min и преобразовать оставшееся значение в число.

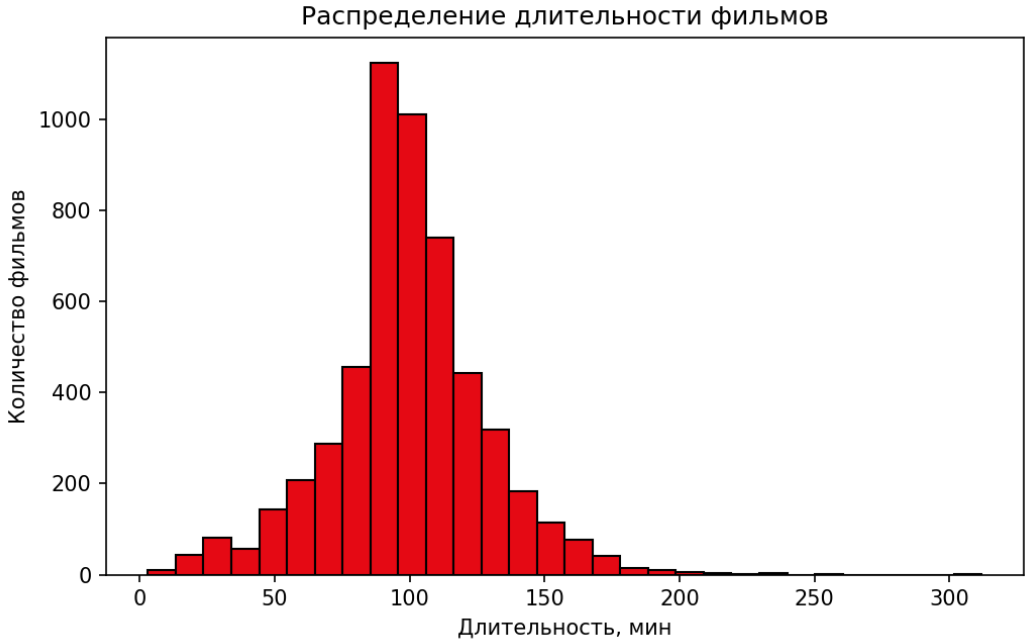


Рисунок 4. Распределение длительности фильмов на Netflix

В конце я посмотрел, какие возрастные рейтинги встречаются в датасете чаще всего.



Результаты

- Фильмов в каталоге заметно больше, чем сериалов: 5377 против 2410.
- США дают больше всего записей в датасете. На втором месте находится Индия.
- По графику видно, что примерно с 2015-2016 года количество контента начинает расти намного быстрее.
- Средняя длительность фильма получается около 100 минут.
- Чаще всего встречается рейтинг TV-MA, поэтому большая часть контента в датасете рассчитана на взрослую аудиторию.